


L'Architettura della Regressione Lineare

Dal calcolo deterministico all'inferenza probabilistica:
un'analisi profonda dei minimi quadrati



Dipartimento di Scienze Informatiche

Dalla Nube di Punti alla Relazione Algebrica




L'Osservazione:

Partiamo da un set di dati $\{(x_i, y_i), i=1, \dots, n\}$. Il diagramma a dispersione (scatterplot) è la prima lente diagnostica.



L'Obiettivo:

Esiste una relazione lineare? Se conosciamo una variabile indipendente X , possiamo prevedere con precisione la variabile dipendente Y ?



Il Problema Geometrico:

Ad occhio nudo possiamo tracciare una retta, ma come definiamo e misuriamo matematicamente la "retta migliore in assoluto"?






Diagramma a Dispersione dei Dati x-y



Dati x-y con Linea di Regressione

Il Metodo dei Minimi Quadrati: Ottimizzare la Distanza

Il miglior stimatore minimizza la distanza quadratica media. Per trovare la retta perfetta, dobbiamo trovare le costanti a e b che portano questa funzione al suo minimo assoluto.



$$f(a, b) = E(Y - a - bX)^2$$

Il valore reale osservato.

La nostra
approssimazione lineare.

La penalizzazione quadratica
per evitare che errori positivi
e negativi si annullino.

La Derivazione Matematica dei Parametri a e b

Il Calcolo - Proposition 6.1

Calcoliamo le derivate parziali e poniamole a zero:

$$f_a = -2E(Y - a - bX) = 0$$

$$f_b = -2E[X(Y - a - bX)] = 0$$

La Soluzione

Riscrivendo le equazioni utilizzando la covarianza, otteniamo i parametri esatti:

Pendenza (**Slope**):

$$b = \frac{Cov(X, Y)}{\sigma_X^2} = \rho(X, Y) \cdot \frac{\sigma_Y}{\sigma_X}$$

Intercetta (**Intercept**):

$$a = EY - bEX$$


Nota geometrica: La retta dei minimi quadrati passerà sempre per il punto medio (EX, EY).

Il Modello Probabilistico: L'Ingresso dell'Incertezza (ϵ)

$$Y = \underbrace{a + bx}_{\text{La componente deterministica (il segnale)}} + \underbrace{\epsilon}_{\text{Il termine di errore o rumore casuale (il disturbo)}}$$

La componente deterministica (il segnale).

Il termine di errore o rumore casuale (il disturbo).



Le 3 Assunzioni Fondamentali

1. Normalità

Gli errori seguono una distribuzione normale: $\epsilon \sim N(0, \sigma)$.

2. Media Zero

Per ogni x , il valore atteso dell'errore è strettamente nullo.

3. Varianza Costante

La deviazione standard σ è identica e costante lungo tutta la retta (omoschedasticità).

Anatomia della Varianza (ANOVA): Decostruire l'Errore

$$SST = SSR + SSE$$

SST (Caos Totale)

$$\sum SSR$$

$$\sum SSE$$

Definitions Matrix

SST (Total Sum of Squares)	SSR (Regression Sum of Squares)	SSE (Error Sum of Squares)
$\sum (y_i - \bar{y})^2$ La variazione totale dei valori Y rispetto alla loro media. Il caos totale dei dati.	$\sum (\hat{y}_i - \bar{y})^2$ La variazione spiegata dal nostro modello lineare. La nostra vittoria.	$\sum (y_i - \hat{y}_i)^2$ La variazione residua o inspiegata. Il rumore intrinseco ineliminabile.

Key Insight: Un modello perfetto ha $SSE = 0$. Un modello completamente inutile ha $SSR = 0$.


Giudicare il Modello: Il Coefficiente di Determinazione (r^2)

Case Study: Record mondiali dei 100 metri maschili (1963–2009)

$$r^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$


Correlazione r	-0.914 (Forte tendenza negativa)
SST	0.0306
SSR	0.0256
SSE	0.0050

Interpretazione Reale: Il modello spiega l'83.6% (r^2) della varianza nei tempi dei 100 metri. Il restante 16.4% è dovuto a variabili non misurate dal tempo puro (es. vento, nutrizione, biomeccanica).



Distribuzioni Campionarie: La Dinamica di a e b

Teorema 6.15: Essendo calcolati da un campione casuale, i parametri dell'intercetta (a) e della pendenza (b) non sono costanti fisse, ma variabili casuali.



Intercetta ($\hat{a}$)	Pendenza ($\hat{b}$)
$\hat{a} \sim N\left(a, \sigma \sqrt{\frac{\sum x_i^2}{n} S_{xx}}\right)$	$\hat{b} \sim N\left(b, \frac{\sigma}{\sqrt{S_{xx}}}\right)$

Key Insight: La precisione della nostra pendenza ($\hat{b}$) dipende dalla varianza intrinseca (σ) divisa per la dispersione dei nostri dati X (S_{xx}). Più i dati di input sono ampi e dispersi, più la pendenza è sicura e stabile.

Inferenza Statistica: Il Test t di Student

1. Il Problema

Non conosciamo la vera varianza dell'errore (σ).

2. La Soluzione

Lo sostituiamo con lo Standard Error of the

$$\text{Estimate: } s = \sqrt{\frac{SSE}{n-2}}$$

3. La Trasformazione

Sostituendo σ con s , la distribuzione normale subisce un mutamento e diventa una distribuzione t con $n-2$ gradi di libertà (Teorema 6.16).

Test delle Ipotesi ($H_0: b = b_0$)

$$t_{b0} = \frac{\hat{b} - b_0}{SE(\hat{b})}$$

Applicazione Pratica: Usato tipicamente per testare $H_0: \hat{b} = 0$. Ci chiediamo: esiste davvero una relazione lineare o la pendenza reale è pari a zero?

Intervalli a Confronto: Prevedere la Media vs. Prevedere il Singolo

Banda di Confidenza

Obiettivo: Stimare la risposta media (μ_p) per un dato input x_p .

$$\mu_p \pm t\left(n-2, \frac{\alpha}{2}\right) s \sqrt{\frac{1}{n} + \frac{(x_p - \bar{x})^2}{S_{xx}}}$$

Significato: Qual è l'altezza media di tutti i figli di padri alti 180cm?

Banda di Previsione


Obiettivo: Stimare un singolo valore futuro (y_p) per un dato input x_p .

$$y_p \pm t\left(n-2, \frac{\alpha}{2}\right) s \sqrt{1 + \frac{1}{n} + \frac{(x_p - \bar{x})^2}{S_{xx}}}$$

Significato: Quale sarà l'altezza esatta di questo specifico figlio?

La Banda di Previsione deve incorporare la varianza individuale (il fattore +1), rendendola matematicamente e fisicamente sempre più larga.

La Geometria dell'Incertezza: Il Fenomeno Flaring



Contesto Storico: I dati di Galton sull'altezza padri/figli e il concetto originale di 'regressione verso la media'.

→ **Centro più stretto:** Le bande sono più strette al punto medio $(\bar{x}, \bar{y})$. L'incertezza è minima qui.


→ **Estremi svasati (Flaring):** Man mano che ci si allontana dalla media di X , la penalizzazione quadratica cresce, allargando le bande ad imbuto.

→ **Larghezza strutturale:** Le linee di previsione (esterne) sono sempre drasticamente più larghe di quelle di confidenza a causa dell'incertezza ineludibile del singolo individuo.

Analisi dei Residui: Il Battito Cardiaco del Modello

Definizione: I residui ($\hat{\varepsilon}_i = y_i - \hat{y}_i$) rappresentano la differenza esatta tra il dato osservato e il valore calcolato sulla retta.

Proprietà Geometrica Fondamentale: In un modello dei minimi quadrati, la somma dei residui è sempre zero ($\sum \hat{\varepsilon}_i = 0$).



Diagnosi Visiva

A

Sano (Modello Corretto)



Il grafico dei residui appare come una dispersione puramente casuale attorno allo zero (rumore bianco). Nessun pattern discemibile.

B

Malato (Modello Errato)



Tendenze coerenti, forme a imbuto o curvature a "U" indicano che una regressione non lineare o una trasformazione dei dati sarebbe più appropriata.

Identificazione degli Outlier: La Regola del $\pm 2s$

The Metric

Usiamo il doppio dello standard error ($2s$) per creare una banda di tolleranza attorno alla retta di regressione.


The Rule

In una distribuzione normale, il $\approx 95\%$ dei dati validi cadrà entro questa banda di confidenza parallela.


Azione Diagnostica

- Qualsiasi punto isolato al di fuori del limite $2s$ è considerato matematicamente un Outlier.
- Gli outlier in modelli lineari creano una distorsione a leva (leverage) drastica, alterando severamente la pendenza stimata.
- La rimozione (previo severo controllo di validità del dato) stabilizza i parametri $\hat{a}$ e $\hat{b}$, riportando l'equilibrio.

Scatterplot con Banda di Tolleranza $\pm 2s$



Sintesi: Il Ciclo Vitale del Modello Lineare



La regressione lineare non è semplicemente tracciare una linea. È l'architettura matematica che ci permette di quantificare razionalmente la nostra incertezza riguardo al futuro.

Esercizio

Si ritiene che più alcool c'è in circolo, più lento sia il tempo di reazione di una persona. Per verificare questa affermazione, 7 volontari assumono ciascuno una diversa quantità di alcool. La concentrazione di alcool nel sangue viene determinata come percentuale del peso corporeo. In seguito viene misurato il tempo di reazione di ciascuno a un certo stimolo, ottenendo i seguenti dati.

x=concentrazione di alcool nel sangue (%)	y= tempo di reazione (secondi)
0.08	0.32
0.10	0.38
0.12	0.44
0.14	0.42
0.15	0.47
0.16	0.70
0.18	0.63

- Disegnare il grafico a dispersione dei dati.
- Disegnare la retta di regressione.
- Usare la retta di regressione per predire il tempo di reazione di un individuo con una concentrazione di alcool nel sangue di $x=0.15$.
- Disegnare il grafico dei residui. Cosa ci dice?
- Determinare l'indice di determinazione. Come lo interpretiamo?