

# Adaptive Learning 5.0: un'architettura a retroazione per la personalizzazione etica della didattica

Antonio Adinolfi

Liceo Scientifico Statale “Nino Cortese”, Maddaloni (CE), Italia — Ordine degli Ingegneri della  
Provincia di Caserta  
email: [adinolfi.a@gmail.com](mailto:adinolfi.a@gmail.com)

## Abstract

La didattica tradizionale eroga a tutti gli studenti lo stesso percorso, la stessa verifica e la stessa valutazione, mentre i dati INVALSI mostrano bisogni di apprendimento fortemente eterogenei. Il presente contributo propone Closed-Loop Adaptive Education (CLAE), un'architettura che riformalizza l'Adaptive Learning nel linguaggio della teoria dei controlli e ne riorganizza il framework operativo come architettura di riferimento a livelli, distinguendosi da recenti sistemi closed-loop già validati empiricamente (es. EduLoop-Agent) per il taglio formativo rivolto ai docenti come costruttori, non solo utilizzatori, di ambienti adattivi. Il framework, denominato F.L.O.W. (Feedback Learning Optimization Workflow), è stato utilizzato per progettare il percorso di formazione docenti “Adaptive Learning 5.0” nell'ambito del progetto PNRR “DI.CO. – Digital Community: Hub dell'IA per l'evoluzione del Sistema scuola”. Il contributo discute inoltre le implicazioni etiche della personalizzazione algoritmica, in coerenza con i temi di AI Literacy ed equità promossi da questa edizione del convegno.

**Parole chiave:** Adaptive Learning, Learning Analytics, sistemi a retroazione, Digital Twin dello studente, Explainable AI, formazione docenti (Teacher Education).

## 1 Introduzione

Il modello didattico prevalente nella scuola italiana continua a proporre la stessa lezione, lo stesso libro, gli stessi esercizi e la stessa verifica a classi composte da studenti con competenze, ritmi e stili cognitivi profondamente diversi. Settori extra-scolastici che gestiscono utenze altrettanto eterogenee — dai servizi di streaming al commercio elettronico — hanno da tempo adottato logiche di personalizzazione automatica basate sull'osservazione continua del comportamento dell'utente. La scuola, al contrario, resta in larga parte un sistema a catena aperta (open-loop), nel quale il segnale di

ritorno — il voto — arriva a valutazione conclusa e non modifica in tempo reale il processo di insegnamento.

I dati resi disponibili da INVALSI confermano che le difficoltà degli studenti non derivano soltanto da lacune nozionistiche, ma da problemi di comprensione concettuale, difficoltà nel trasferire conoscenze a contesti nuovi e criticità linguistiche che condizionano anche l'apprendimento matematico. Questo scenario rende necessario un ripensamento strutturale, non incrementale, della didattica: non più “usare l'IA” come strumento accessorio, ma progettare ambienti che osservano, interpretano e reagiscono agli errori in tempo reale.

## 2 Dai sistemi tutor intelligenti ai sistemi a retroazione

La letteratura sull'Intelligent Tutoring Systems (ITS) ha da tempo dimostrato che sistemi in grado di adattare contenuti e difficoltà al singolo studente producono guadagni di apprendimento comparabili, in molti contesti, al tutoraggio umano individuale (VanLehn, 2011). Parallelamente, la ricerca sull'Adaptive Hypermedia ha definito i costituenti fondamentali di un sistema adattivo: un modello dello studente (Student Model), un modello del dominio di conoscenza (Domain Model) e un modello pedagogico che decide le azioni successive (Brusilovsky, 2001).

Contributi recenti mostrano che il ciclo chiuso non è più soltanto un'aspirazione teorica. Wang et al. (2025) propongono EduLoop-Agent, un agente che integra diagnosi cognitiva neurale, item selection adattiva (BECAT) e feedback generato da LLM in un ciclo “Diagnosis–Recommendation–Feedback”, validato quantitativamente sul dataset ASSISTments. Aboulsafa et al. (2025) propongono un modello dati e un'architettura di sistema per uno Student Digital Twin alimentato da dispositivi IoT in tempo reale, con una sperimentazione preliminare. Questi lavori confermano che il paradigma closed-loop è un'area di ricerca già attiva e, a differenza del presente contributo, offrono validazione empirica quantitativa: un limite che questo lavoro dichiara esplicitamente (Sezione 6).

Rispetto a questi sistemi, prevalentemente orientati alla pipeline tecnica (modellazione, selezione item, generazione di feedback), il contributo specifico di questo lavoro non è l'introduzione del ciclo chiuso in sé, ma (i) la sua formalizzazione esplicita nel linguaggio della teoria dei controlli (stato, azione, errore, retroazione), (ii) la sua riorganizzazione in un'architettura di riferimento a livelli ispirata a schemi industriali (RAMI 4.0, NIST), e (iii) il suo utilizzo come strumento di formazione per docenti chiamati a costruire, non solo utilizzare, un prototipo di sistema adattivo nella propria disciplina.

Un confronto più puntuale con i due lavori appena richiamati mostra convergenze e differenze specifiche. EduLoop-Agent condivide con CLAE il paradigma closed-loop, ma ne demanda la formalizzazione a una pipeline di apprendimento automatico (diagnosi neurale, selezione adattiva degli item, feedback generato da LLM) già validata quantitativamente su dati reali, laddove CLAE la rende esplicita nel linguaggio dei sistemi di controllo, a costo di non disporre ancora di una validazione comparabile. Il modello di Aboulsafa et al. condivide con CLAE l'idea di un profilo dello studente in evoluzione continua, ma la persegue tramite sincronizzazione IoT in tempo reale, un requisito infrastrutturale che il presente lavoro non assume né richiede. In nessuno dei due lavori il ruolo del docente è discusso come progettista del sistema, né la governance algoritmica è organizzata come livello architetturale dedicato: restano, ad oggi, gli elementi più distintivi di CLAE rispetto alla letteratura qui consultata, in attesa della validazione empirica che ne costituisce il limite principale.

### **Contributi del lavoro**

- una riformulazione dell'Adaptive Learning nel linguaggio dei sistemi a retroazione (CLAE);
- F.L.O.W. come architettura di riferimento a livelli, ispirata a schemi industriali (RAMI 4.0, NIST);
- una prima formalizzazione dinamica del problema, dichiarata esplicitamente come programma di

ricerca futuro e non come risultato acquisito;

- un'applicazione a un percorso di formazione docenti che produce un artefatto reale, non solo un attestato;
- un posizionamento esplicito rispetto a sistemi closed-loop già validati empiricamente (EduLoop-Agent, Student Digital Twin).

### 3 L'architettura Closed-Loop Adaptive Education (CLAE)

Il framework proposto, CLAE, articola il processo didattico in un ciclo Observe → Analyze → Predict → Adapt → Teach → Assess → Learn, con i seguenti componenti:

In quanto segue, CLAE indica l'architettura complessiva a ciclo chiuso qui proposta; F.L.O.W. ne indica specificamente l'organizzazione a livelli descritta nella Sezione 3.1. I due termini non sono sinonimi intercambiabili: CLAE è il modello concettuale, F.L.O.W. è la sua rappresentazione architeturale.

- Student Digital Twin: modello dinamico e non solo descrittivo dello studente, che integra competenze disciplinari, errori ricorrenti, tempi di risposta, carico cognitivo stimato e indicatori motivazionali, aggiornato ad ogni interazione. Il termine è qui impiegato nell'accezione, già diffusa in letteratura educativa, di profilo dinamico e continuamente aggiornato: non si rivendica la sincronizzazione in tempo reale né la capacità simulativa predittiva richieste dall'accezione ingegneristica più stretta del termine.
- Decision Engine: componente basato su modelli di intelligenza artificiale (inclusi Large Language Model) che seleziona l'attività successiva non in funzione del “prossimo esercizio” ma dell'azione che massimizza l'apprendimento atteso, secondo una logica assimilabile a un problema di ottimizzazione con rinforzo (reward positivo in caso di miglioramento misurato, negativo in caso contrario).
- Assessment Engine e Learning Analytics: raccolta continua di evidenze (quiz, tempi, errori, interazioni) e restituzione al docente tramite dashboard, così da mantenere la supervisione umana sul processo decisionale dell'IA (Explainable AI).

La Figura 1, riportata al termine del contributo, sintetizza in un unico schema il ciclo di controllo appena descritto, mostrando come gli obiettivi didattici, l'azione selezionata dal Decision Engine e l'osservazione dello stato dello studente si richiudano in un anello di retroazione.

#### 3.1 F.L.O.W. come Reference Architecture

Per dare al framework una struttura riconoscibile anche al di fuori del dominio educativo, F.L.O.W. (Feedback Learning Optimization Workflow) viene qui riformulato non come semplice sequenza operativa ma come architettura di riferimento a livelli, sul modello di schemi consolidati nell'automazione industriale (es. RAMI 4.0) e nella sicurezza informatica (es. i modelli a livelli NIST):

Livello 1 – Learning Analytics: acquisizione ed elaborazione delle evidenze grezze (quiz, tempi di risposta, errori, interazioni).

Livello 2 – Digital Twin dello studente: modello dinamico e continuamente aggiornato dello stato cognitivo e motivazionale, costruito a partire dal Livello 1.

Livello 3 – Decision Engine: selezione dell'azione didattica successiva sulla base dello stato corrente del Digital Twin.

Livello 4 – Explainable AI: traduzione delle decisioni del Livello 3 in motivazioni leggibili e verificabili dal docente.

Livello 5 – Governance: supervisione umana, criteri di equità algoritmica e conformità al trattamento dei dati, trasversale agli altri livelli.

Questa stratificazione rende esplicito che nessun livello opera in autonomia rispetto agli altri: in particolare il Livello 5 non è un livello “superiore” ma una funzione di controllo trasversale, coerentemente con quanto discusso nella Sezione 5.

### 3.2 Verso una formalizzazione matematica

Il framework qui presentato è attualmente descrittivo; una sua evoluzione naturale, che indichiamo come direzione di lavoro futuro e non come risultato già conseguito, consiste nel rendere esplicito il modello dinamico sotteso al Digital Twin. Indicando con  $x(k)$  lo stato — competenze, errori ricorrenti, carico cognitivo stimato — dello studente al passo  $k$ , con  $u(k)$  l'azione didattica selezionata dal Decision Engine e con  $y(k)$  la prestazione osservata a seguito di tale azione, il ciclo di controllo può essere sintetizzato dall'equazione di aggiornamento:\*

$$x(k+1) = f(x(k), u(k)), \quad e(k) = r(k) - y(k)$$

dove  $r(k)$  rappresenta l'obiettivo di apprendimento atteso ed  $e(k)$  l'errore rispetto ad esso, utilizzato dal Decision Engine per selezionare  $u(k+1)$ . La stima della funzione  $f(\cdot)$  — tramite modelli statistici, reti neurali o politiche di rinforzo — e la sua validazione empirica su dati reali costituiscono l'oggetto di un successivo lavoro, già impostato come proseguimento diretto del presente contributo (cfr. Sezione 6).

## 4 Applicazione: il percorso di formazione “Adaptive Learning 5.0”

Il framework CLAE/F.L.O.W. è stato utilizzato per progettare il percorso formativo rivolto ai docenti “Adaptive Learning 5.0 – Costruire sistemi intelligenti che imparano dagli studenti”, realizzato nell'ambito del progetto PNRR “DI.CO. – Digital Community: Hub dell'IA per l'evoluzione del Sistema scuola”, dedicato agli Snodi Formativi per la transizione digitale. A differenza dei percorsi centrati sull'uso diretto di chatbot generativi, il corso guida i docenti a progettare, con strumenti a costo pressoché nullo (Google Forms, Google Apps Script, API di modelli linguistici, fogli elettronici), un prototipo funzionante di ambiente adattivo per la propria disciplina, restituendo al termine un artefatto operativo anziché un mero attestato di partecipazione.

Il percorso propone, tra gli esempi di progetto finale, applicazioni per Matematica (verifica iniziale → percorso di recupero automatico → verifica finale), Italiano (comprensione del testo con esercizi differenziati) e Informatica (coding adattivo con feedback automatico), mostrando come la medesima architettura di controllo si adatti a domini disciplinari eterogenei.

## 5 Considerazioni etiche

La personalizzazione algoritmica dell'apprendimento pone questioni etiche che non possono essere eluse. In primo luogo, la profilazione continua dello studente richiede una gestione dei dati conforme ai principi di minimizzazione e trasparenza, con il docente mantenuto nel ciclo decisionale (human-in-the-loop) e non sostituito da esso. In secondo luogo, un sistema che apprende dagli errori pregressi rischia di consolidare bias di valutazione se non periodicamente auditato: la letteratura su AI Literacy ed equità (UNESCO, 2021) raccomanda che i sistemi adattivi siano accompagnati da percorsi di alfabetizzazione critica rivolti sia ai docenti sia agli studenti, così che la personalizzazione non diventi

---

\* È disponibile come materiale supplementare una simulazione numerica del modello proposta come proof-of-concept del ciclo di controllo.

un meccanismo opaco di etichettamento. Coerentemente con il quadro DigCompEdu (Redecker, 2017), il percorso formativo qui descritto dedica un modulo esplicito alla spiegabilità delle decisioni dell'IA, richiedendo che ogni raccomandazione generata dal Decision Engine sia accompagnata da una motivazione leggibile dal docente.

## 6 Conclusioni e sviluppi futuri

Il contributo ha presentato una formalizzazione ingegneristica dell'Adaptive Learning come sistema di controllo a retroazione, distinguendola dai sistemi che modificano soltanto la difficoltà locale degli esercizi, e ne ha riorganizzato il framework operativo (F.L.O.W.) come architettura di riferimento a livelli. Il modello è stato tradotto in un percorso di formazione docenti replicabile in altri Snodi Formativi PNRR. Il presente lavoro è volutamente concettuale: la sua natura preliminare è dichiarata anche nello sketch di formalizzazione della Sezione 3.2, che non costituisce un modello validato ma la traccia di un programma di ricerca articolato in tre fasi successive: (i) definizione formale della funzione di transizione  $f(\cdot)$  e della politica di selezione delle azioni; (ii) implementazione di un prototipo e sperimentazione in una o più classi con raccolta strutturata di Learning Analytics; (iii) analisi quantitativa dei risultati, confronto con una didattica non adattiva e valutazione degli aspetti di equità algoritmica nel contesto della povertà educativa digitale.

L'obiettivo di lungo periodo è verificare se una formalizzazione control-theoretic possa costituire un linguaggio comune per la progettazione, il confronto e la valutazione di sistemi di Adaptive Learning eticamente orientati.

## Riferimenti bibliografici

Aboulsafa, E., Elkhayat, G., Abdul-kader, H., & Almorsy, S. (2025). Proposed Student Digital Twin Data Model and System Architecture for Personalized Learning. 2025 International Conference on Machine Intelligence and Smart Innovation (ICMISI), 341–346.

Brusilovsky, P. (2001). Adaptive Hypermedia. *User Modeling and User-Adapted Interaction*, 11, 87–110.


Redecker, C. (2017). European Framework for the Digital Competence of Educators: DigCompEdu. Publications Office of the European Union.

UNESCO (2021). AI and Education: Guidance for Policy-makers. UNESCO Publishing.

VanLehn, K. (2011). The Relative Effectiveness of Human Tutoring, Intelligent Tutoring Systems, and Other Tutoring Systems. *Educational Psychologist*, 46(4), 197–221.

Wang, Z., Zheng, X., & Zeng, C. (2025). EduLoop-Agent: A Closed-Loop Personalized Learning Agent Integrating Neural Cognitive Diagnosis, Bounded-Ability Adaptive Testing, and LLM-Driven Feedback. arXiv:2510.22559.

INVALSI (2026). Cosa ci dicono i dati sulle difficoltà in Matematica. [www.invalsi.it](http://www.invalsi.it).



**Figura 1.** Ciclo di controllo dell'architettura CLAE. Gli obiettivi didattici  $r(k)$  guidano il Decision Engine, che seleziona l'azione  $u(k)$  (attività di apprendimento e/o verifica). L'esito aggiorna lo Student Digital Twin, la rappresentazione dinamica dello stato  $x(k)$  dello studente. Il livello Learning Analytics osserva questo stato producendo  $y(k)$ ; lo State Observer lo confronta con l'obiettivo, calcola l'errore  $e(k) = r(k) - y(k)$  e lo restituisce al Decision Engine, chiudendo il ciclo di retroazione. La figura rende visivamente il legame tra l'architettura descritta nella Sezione 3 e la formalizzazione  $x(k+1) = f(x(k), u(k))$  introdotta nella Sezione 3.2; i livelli Explainable AI e Governance (Sezione 3.1) sono trasversali all'intero ciclo e non sono qui rappresentati per non appesantire il diagramma.